

Klasyfikacja

Uczenie Maszynowe
uczeniemaszynowe@cs.uni.wroc.pl

04.11.2025, 10:00
pracowania

Zadanie 1. [1 pkt]

Powtórz zadanie 3 z listy 2 dla modelu kNN. Użyj danych `advertising.csv`. Zbuduj modele kNN na danych, w których skala zmiennych jest zachowana i na danych znormalizowanych. Porównaj te dwa modele, zapisz obserwacje i wnioski.

Zadanie 2. [2 pkt]

- Zbuduj model regresji logistycznej na danych `bank.csv`¹. Porównaj wyniki dla progów $[0.1, 0.25, 0.5, 0.75, 0.9]$.
- Następnie wylicz TPR i FPR dla progów $[0, 0.01, 0.02, \dots, 0.98, 0.99, 1]$ i wyrysuj krzywą ROC.
- Wybierz optymalny próg zakładając, że koszt błędu pierwszego rodzaju (False Positive) wynosi 10, a koszt błędu drugiego rodzaju (False Negative) wynosi 3.
- Wybierz dwa najlepsze predykatory i zbuduj model używając jedynie tych dwóch zmiennych. Dla wybranego progu zaznacz obszary, które klasyfikowane są do obu klas. Co charakterystycznego dostrzegasz? Jak granica między klasami ma się do wektora parametrów modelu?

Zadanie 3. [2 pkt]

W tym zadaniu przyjrzymy się, jak podobieństwa między produktami są kodowane w zanurzeniach produktów uzyskanych z systemu rekomendacyjnego.

W pliku `embeddings.pkl` znajduje się macierz zanurzeń produktów, gdzie każdy wiersz macierzy odpowiada jednemu produktowi. Zanurzenia te uzyskano z systemu rekomendacyjnego². W pliku `item_list.txt` znajdują się oryginalne identyfikatory produktów. W pliku `meta_Books.json.gz`³ znajdują się metadane produktów – nasze embeddingi dotyczą produktów z kategorii Books. Identyfikator produktu znajduje się w polu `asin`.

¹<https://www.kaggle.com/datasets/janiobachmann/bank-marketing-dataset/data>

²<https://github.com/kuandeng/LightGCN>

³informacje i dodatkowe instrukcje: <https://cseweb.ucsd.edu/~jmcauley/datasets/amazon/links.html>

Podziel dane na treningowe i testowe; w razie potrzeby możesz też wydzielić dodatkowy zbiór walidacyjny. Użyj modelu kNN do klasyfikacji kategorii i podkategorii produktów, które znajdziesz w metadanych. Sprawdź, jaka metryka jest odpowiednia dla tego zadania.

Wskazówki:

- Zwróć uwagę na różne formaty danych wejściowych. Mamy plik zapisany binarnie z wykorzystaniem biblioteki `pickle`, plik tekstowy oraz skompresowany plik w którym każda linijka jest jsonem.
- Informacje o metrykach dostępnych w pakiecie `sklearn`: <https://docs.scipy.org/doc/scipy/reference/spatial.distance.html>.
- Zwróć uwagę czy produkt ma jedną czy więcej klas, zastanów się jak należałoby taką sytuację obsłużyć. Być może będzie Ci wygodnie zaproponować własną implementację modelu.

Zadanie 4. [2.5 pkt]

Zbuduj model regresji logistycznej na danych `adult.csv`⁴ przewidujący, czy dana osiąga przychody powyżej \$50k. Skorzystaj z biblioteki `statsmodels`⁵. Przeprowadź procedurę wyboru zmiennych używając następującej procedury:

- Zbuduj model bazowy.
- Sprawdź rezultaty włączenia każdej z nieużytych zmiennych.
- Wytypuj zmienną, która daje największy wzrost jakości modelu.
- Za pomocą wybranego kryterium informacyjnego (AIC, BIC) sprawdź, czy ma sens włączenie tej zmiennej do modelu.
- Jeżeli tak, włącz zmienną do modelu i wytypuj kolejny najlepszy predyktor. W przeciwnym wypadku zakończ nie włączając wytypowanej zmiennej, zakończ procedurę.

Przeprowadź ewaluację uzyskanego modelu.

Wskazówki:

- Możesz pobrać dane bezpośrednio z Kaggle'a:

```
import kagglehub

# Download latest version
path = kagglehub.dataset_download("uciml/adult-census-income")

print("Path to dataset files:", path)
```

- Przydatne metody i atrybuty: `model.summary()`, `model.aic`, `model.bic`.
- Aby dopasować intercept użyj `statsmodels.tools.add_constant`.

⁴<https://www.kaggle.com/datasets/uciml/adult-census-income>

⁵https://www.statsmodels.org/stable/generated/statsmodels.discrete.discrete_model.Logit.html

Zadanie 5. [2.5 pkt]

Zapoznaj się z danymi `Titanic Dataset.csv`⁶. Uzupełnij puste wartości na dwa sposoby, zgodnie z instrukcją poniżej. Następnie porównaj modele regresji logistycznej przewidujące zmienną `survived`.

- Sprawdź jaki odestek brakujących wartości w kolejnych kolumnach.
- Sprawdź czy istnieje zależność między zmiennymi czynnikowymi a brakującymi wartościami w kolumnach numerycznych?
- Rozwiązanie baselinowe:
 - usuń kolumny o wysokim udziale pustych wartości,
 - uzupełnij brakujące wartości numeryczne średnią danej cechy,
 - w przypadku zmiennych kategorycznych najczęstszą wartością.
- Rozwiązanie zaawansowane:
 - zmienną `Cabin` zamień na zmienną kategoryczną informującą czy wartość była pusta,
 - wyekstrahuj tytuły ("Mr", "Mrs", ...) z imion pasażerów, użyj ich do uzupełniania wieku pasażerów uzupełniając wiek medianą dla osób o danym tytule,
 - pozostałe jak wyżej.

Dyskusja na pracownię

- Jakie są inne możliwe procedury wyboru zmiennych do modelu?
- Przeanalizuj sens metod uzupełniania brakujących wartości zaproponowanych dla kolejnych kolumn.

⁶<https://www.kaggle.com/code/sakshisatre/titanic-s-missing-data-visualizing-null-values/input>