Grupowanie - wstęp

Uczenie Maszynowe
uczeniemaszynowe@cs.uni.wroc.pl

termin, 18.11.2025 10:00
ćwiczenia / pracowania

Zadanie 1. [2 pkt]

W tym zadaniu zbudujesz naiwny klasyfikator Bayesowski[1] dla danych `Titanic Dataset.csv`[2].

1. Możesz skorzystać z przygotowania danych z listy czwartej.
2. Aby zbudować model `CategoricalNB`, przetwórz zmienne numeryczne na kategoryczne, zamieniając dokładne wartości na przyporządkowanie do odpowiedniej grupy wartości. Wartości pogrupuj poprzez:
   - podzielenie zakresu zmiennych na równe części,
   - podzielenie obserwacji treningowych na równoliczne części,
   - klasteryzację wartości każdej zmiennej.
3. Zbuduj modele. Porównaj wyniki klasyfikatora dla różnych metod kwantyzacji zmiennych i różnych liczb grup ($k = 2, 5, 10, 25$). Wyniki zbierz w tabeli.

Wskazówki:

- Aby znaleźć wartości rozdzielające równoliczne grupy, możesz użyc funkcji `np.quantile`[3].

Zadanie 2. [2 pkt]

Dla (syntetycznych) zbiorów danych `data<index>.csv`[4] (`index` $\in 1, 2, \ldots, 5$) zbuduj modele k-średnich i mieszaniny gaussowskiej z $k = 3$ komponentami. Na podstawie wizualizacji oceń, który model (kMeans[5] czy GMM[6]) radzi sobie lepiej.

[1] https://scikit-learn.org/stable/modules/generated/sklearn.naive_bayes.CategoricalNB.htmlsklearn.naive_bayes.CategoricalNB
[2] https://www.kaggle.com/code/sakshisatre/titanic-s-missing-data-visualizing-null-values/input
[3] https://numpy.org/doc/2.3/reference/generated/numpy.quantile.html
[4] https://numpy.org/doc/2.3/reference/generated/numpy.load.htmlnumpy.load
[5] https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html
[6] https://scikit-learn.org/stable/modules/generated/sklearn.mixture.GaussianMixture.html

Zadanie 3. [2 pkt]

Bazyli pasjonuje się fotografią. Po kilku latach udało mu się zebrać dość pokaźną kolekcję zdjęć. Mając solidny zbiór danych postanowił, że wytrenuje na nim klasyfikator. Zabrał się więc za anotowanie zdjęć, co okazało się zajęciem żmudnym i nudnym. Poprzestał więc na kilkunastu przykładach. Bazyli nie dał jednak za wygraną i sięgnął po pretrenowany model. Udało mu się uzyskać reprezentacje wszystkich jego zdjęć, lecz nadal nie wiedział jak przypisać im odpowiednie klasy. Pomóż Bzylemu dokończyć to zadanie.

W pliku `image_emb.npy`[7] znajdziedz zanurzenia zdjęć. W pliku `image_labels.npy` znajdziesz indeksy i klasy przypisane do wybranych zdjęć (po kilka z każdej klasy). W plikach `image_emb_test.npy` i `image_labels_test.npy` znajdziesz dane pozwalające przetestować swoje rozwiązanie.

Wskazówki:

- Przeprowadź klasteryzację zanurzeń.
- Przetłumacz przynależność do klastra na przynależność do klasy.
- Ewaluuj swoje rozwiązanie jak standadowe rozwiązanie klasyfikacyjne.

Zadanie 4. [2 pkt]

Zbuduj odpowiedni model grupujący dane `fetch_20newsgroups`[8]. Dobierz liczbę klastrów na podstawie współczynnika Silhouette. Zwizualizuj i opisz, jak wybrać liczbę klastrów na podstawie *metody łokcia* dla średniego błędu kwantyzacji. Korzystając z oryginalnych tekstów, przeanalizuj, jakie grupy tematyczne zostały odkryte.

Wskazówki:

- Przedstaw teksty jako wektory. Możesz wzorować się na poniższym kodzie.

```
from sklearn.datasets import fetch_20newsgroups
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.decomposition import KernelPCA
from sklearn.pipeline import Pipeline

newsgroups_train = fetch_20newsgroups()

# Create a pipeline with TfidfVectorizer and PCA
pipeline = Pipeline([
    ('tfidf', TfidfVectorizer()),
    ('pca', KernelPCA(n_components=100, random_state=42))
])

# Fit and transform the data using the pipeline
pca_matrix = pipeline.fit_transform(newsgroups_train.data)
```

[7] model ResNet50 https://docs.pytorch.org/vision/main/models/generated/torchvision.models.resnet50.html, zbiór danych CIFAR10 https://www.cs.toronto.edu/ kriz/cifar.html

[8] https://scikit-learn.org/stable/modules/generated/sklearn.datasets.fetch_20newsgroups.html

```
# Display the shape of the resulting matrix
print("Shape of PCA matrix:", pca_matrix.shape)
```

- Aby zwizualizować klastry na dwuwymiarowym wykresie, możesz użyć metody redukcji wymiarowości, np. tSNE.

```
from sklearn.manifold import TSNE
import matplotlib.pyplot as plt

tsne = TSNE(n_components=2, random_state=42, perplexity=15)
matrix_2d = tsne.fit_transform(pca_matrix)

plt.scatter(matrix_2d[:, 0], matrix_2d[:, 1], c=cluster_labels)
```

Zadanie 5. [2 pkt]

Zaproponuj własną implementację algorytmu k-średnich. Wytrenuj model dla danych `fetch_20newsgroups`[9]. Zwizualizuj proces treningu modelu. Zaproponuj modyfikację algorytmu do wersji *online* , tak aby aktualizował się do bieżąco spływających danych. Zwizualizuj proces dotrenowywania modelu *online*.
Wskazówki:

- Użyj interaktywnych wizualizacji lub animacji.
- Podziel dane na dane do pretrenowania modelu (np. 30%) i do dotrenowywania online.
- Rób iteracje dla małych porcji sływających danych (niekoniecznie dla każdej obserwacji osobno).

Dyskusja na pracownię

- Proste metody wekotryzacji tesktów (bag of words, TF-IDF)

[9] https://scikit-learn.org/stable/modules/generated/sklearn.datasets.fetch_20newsgroups.html